FACULTAD DE INGENIERIA

BIOINGENIERIA

Proyecto 1: Análisis de señales ECG y detección de arritmias Proyecto 2026-02

Presentado por: Luis Felipe Montoya, Karly Juliana Tarazona

Punto 1: Análisis de metodología de los artículos

1. Artículo **"Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias":**

INICIO
↓
1. Selección y depuración de los registros de ECG
↓
2. División de los datos en entrenamiento, calibración y prueba
↓
3. Extracción y procesamiento de características del ECG
↓
4. Entrenamiento del modelo de predicción de fibrilación auricular
↓
5. Calibración de las probabilidades de riesgo
↓
6. Evaluación del rendimiento del modelo
↓
FIN

Se tiene como objetivo desarrollar un modelo predictivo capaz de identificar el de fibrilación auricular a corto plazo basándose en señales de electrocardiogramas (ECG) previos que no muestran la arritmia. Ahora los pasos a seguir fueron:

1.1 Selección y caracterización de los individuos en el estudio: En este paso se recopilaron los registros de ECG de derivación única con duración de hasta 40 días obtenidos de parches adhesivos (iRhythm Zio®XT patch). Se definió que un evento positivo de fibrilación auricular (AF) cualquier arritmia mayor a 30 segundos verificada por técnicos del dispositivo y excluyendo pacientes con AF persistente.

1.2 División de los datos: Se dividieron los datos en tres grupos: una cohorte de entrenamiento que tenía 50% de casos positivos de AF para cada rango de edad, una cohorte de calibración con prevalencia natural de los casos que permiten corregir los casos añadidos en la cohorte de entrenamiento y finalmente una cohorte de prueba para calificar el comportamiento del modelo.

1.3 Extracción y procesamiento de características: Se analizaron segmentos de 10 minutos de ECG para obtener información importante de la actividad eléctrica del

corazón. Se sacaron métricas de variabilidad de la frecuencia cardíaca, identificaron ritmos anormales y utilizaron el primer módulo de deep learning para reconocer automáticamente patrones en la señal. Después de esto se limpiaron y transformaron los datos para poder comparar las variables en escalas y distribuciones adecuadas para poder entrenar el modelo.

1.4 Entrenamiento del modelo de predicción: El modelo fue desarrollado usando dos módulos de deep learning. El primero fue usado para extraer características de cada segmento de ECG de 10 minutos. El segundo fue entregado las caracetrísticas de segmentos consecutivos que llegan hasta las 24 horas y usó una red neuronal LSTM bidireccional para un análisis temporal entre segmentos. Así fue que el modelo pudo aprender patrones en el ritmo cardíaco que estuvieran asociados con la aparición fitura de la fibrilación auricular.

1.5 Calibración de las probabilidades de riesgo: Ya con el modelo entrenado, se ajustaron los resultados utilizando la cohorte de calibración. Para hacerlo se usó la técnica de regresión isotónica, la cual relaciona las puntuaciones que genera el modelo con la frecuencia de observación del evento. Esto permitió que esas puntiaciones entregadas por el modelo se convirtieran en probabilidades de riesgo que se pudieran interpretar y comparar entre los grupos de edad.

1.6 Evaluación del rendimiento del modelo: Finalmente se utilizó la cohorte de prueba para evaluar la capacidad predictiva del modelo. Se compararon diferentes características de entrada y duraciones del ECG (10 minutos, 1 hora y 24 horas). También se analizó el rendimiento según la carga de fibrilación auricular del paciente. Para determinar si el modelo podía distinguir entre personas que tuvieran o no eventos futuros se usaron métricas como el AUC y la precisión promedio. También se usaron métodos estadísticos para estimar intervalos de confianza y comparar resultados.

2. Artículo: **"Optimal Multi-Stage Arrhythmia Classification Approach"**

INICIO

↓

1. Selección y etiquetado de los registros ECG

↓

2. Clasificación de los ritmos y organización de los datos

↓

3. Reducción de ruido y reescalado de las señales

↓

4. Extracción y selección de características

↓

5. Entrenamiento y optimización de modelos clasificadores

↓

6. Comparación del rendimiento e identificación del mejor modelo

↓

FIN

En este artículo el objetivo fue desarrollar y comparar modelos de aprendizaje que pudieran clasificar ritmos cardíacos a partir de señales ECG con técnicas de reducción de ruido y extracción de características de las señales para poder identificar una estrategia de clasificación que tuviera el mejor desempeño.

2.1 Selección y etiquetado de los registros ECG: Se usaron 40.258 registros de ECG de 12 derivaciones de pacientes atendidos en hospitales de China entre 2013 y 2018. Cada señal con una duración de 10 segundos a frecuencia de muestreo de 500 Hz. Luego los registros fueron clasificados por médicos supervisores según los ritmos cardíacos identificados y demás alteraciones cardíacas que se tuviera.

2.2 Clasificación de los ritmos: Los datos fueron agrupados en 11 tipos de ritmos cardíacos en cuatro categorías principales: bradicardia sinusal (SB), fibrilación auricular (AFIB), taquicardias supraventriculares (GSVT) y ritmo sinusal (SR). Con esto se pudieron juntar arritmias menos comunes en grupos más amplios que se pudieran clasificar con mayor facilidad. Adicionalmente se creó un subconjunto que no tuviera afecciones cardíacas adicionales para estudiar la influencia de esas alteraciones específicas.

2.3 Reducción del ruido y reescalado: Se usaron tres técnicas de procesamiento para mejorar la calidad de las señales ECG. Primero un filtro Butterworth pasa bajas para el ruido de alta frecuencia, luego el método Robust LOESS para las variaciones de línea base y finalmente el algoritmo NLM para reducir el ruido que quedaba. También reescalaron la amplitud de las señales por normalizarlos y así analizar si cambiaba la clasificación de los datos.

2.4 Extracción y selección de las características: Se desarrolló un método para poder extraer las caracetrísticas relevantes de las señales ECG. Se usó la media de las ondas y los intervalos, los intervalos RR y propiedades de los picos y valles de la señal. También se usaron variables como la edad y el sexo. Se definieron 11 combinaciones de características diferentes con distinta complejidad y así poder estudiar cuáles conjuntos de variables entregaban mejores resultados y poder comparar el ECG de 12 derivaciones y una derivación.

2.5 Entrenamiento y optimización de los modelos: Los investigadores probaron diferentes algoritmos de aprendizaje automático como árboles de decisión, regresion

logística, máquinas de soporte vectorial, redes neuronales y métodos de conjuntos de árboles. También usaron en conjunto clasificadores, estrategias de ensamble y métodos para abordar la clasificación multiclase. Estas pruebas y modelos se hicieron con el objetivo de conocer si el modelo podía diferenciar entre los 4 grupos de ritmos cardíacos y se fueron ajustando parámetros para saber cuáles configuraciones daban mejor resultado.

2.6 Comparación e identificación del mejor modelo: Al final se compararon las diferentes configuraciones que se establecieron para determinar cuáles clasificaban mejor los ritmos cardíacos. Se evaluó el efecto que tenían las características, el reescalado y la presencia de otras afecciones. Se obtuvo como resultado en el artículo que los modelos con mejor rendimiento en la clasificación fueron el Extreme Gradient Boosting y el Gradient Boosting Tree.

3. Artículo **"An Arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection"**

INICIO

↓

1. Selección y extracción de los registros ECG

↓

2. Preparación y segmentación de las señales

↓

3. Organización de los datos para entendimiento y validación

↓

4. Diseño y entrenamiento de la red neuronal convolucional CNN

↓

5. Evaluación de la capacidad de clasificación del modelo

↓

6. Prueba externa con

registros independientes

↓

FIN

En este artículo el objetivo fue desarrollar y evaluar un modelo de aprendizaje basado en redes neuronales convolucionales que pudieran identificar nueve tipos diferentes de ritmos cardíacos a partir de señales o imágenes de ECG de una derivación.

3.1 Selección y extracción de los registros ECG: Se utilizaron tres bases de datos públicas (MIT-BIH Arrhythmia, MIT-BIH Atrial Fibrillation y MIT-BIH Ventricular Fibrillation) para extraer los registros con los nueve tipos de ritmos cardíacos. Todas las señales extraídas fueron de una sola derivación.

3.2 Preparación y segmentación de las señales: En principio se justó la frecuencia de muestreo a 250 Hz para todas las bases de datos. Luego se dividieron las señales en segmentos de 5 y 10 segundos y se solaparon combinando segmentos consecutivos para obtener más muestras. Esto fue hecho con el objetivo de estandarizar todas las muestras y tener grupos de igual tamaño para entrenar el modelo.

3.3 Organización de los datos: Con el objetivo de preparar los datos para el desarrollo del modelo y comparar el desempeño con señales de distinta duración, los investigadores organizaron las muestras para el entrenamiento del modelo con experimentos separados con los registros de 5 y 10 segundos.

3.4 Entrenamiento de la red neuronal: Se construyó la red neuronal que aprende a reconocer patrones a partir de las señales del ECG. Se entrenó la red para ajustar sus parámetros para poder asociar los patrones que encontró con los nueve ritmos cardíacos correspondientes.

3.5 Evaluación del desempeño del modelo: Para evaluar el modelo se analizaron tres métricas: la exactitud, la precisión y sensibilidad. Con esto buscaron medir qué tan bien el modelo podía clasificar los ritmos cardíacos y conocer si había dificultades con algún ritmo.

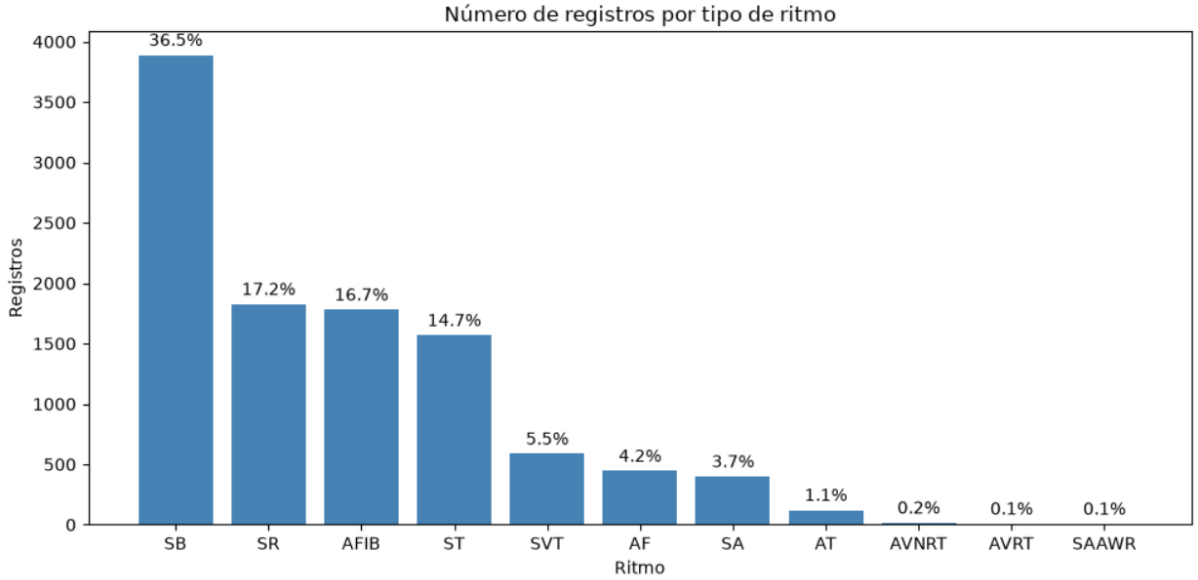
3.6 Prueba externa con datos independientes: Se usó una cuarta base de datos (Creighton University Ventricular Tachyarrhythmia Database) para poder probar el modelo con registros que no fueron utilizados en el entrenamiento. Esto fue hecho para analizar el sobreajuste que puede suceder cuando un modelo usa demasiado una base de datos de entrenamiento y no funciona de manera similar con otras bases de datos.

Punto 2: Análisis estadístico general de los datos

La base de datos Diagnostics.xlsx contiene la información clínica asociada a 10 646 registros de ECG de la colección ChapmanECG. Cada registro tiene el tipo de ritmo (etiqueta de arritmia), el género y la edad del paciente, además de variables como la frecuencia ventricular y auricular, la duración del QRS y los intervalos QT. No se encontraron datos faltantes ni registros duplicados.

La edad de los pacientes va de 4 a 98 años, con una media de 59,2 años y una mediana de 62. El 55,9% de los registros corresponde a hombres, mientras que aproximadamente el 44 % esta representad por mujeres. En la base hay 11 tipos de ritmo. En el análisis que se realizó, se clasificó los registros por ritmo, género y edad.

Los ritmos más frecuentes son la bradicardia sinusal (SB), el ritmo sinusal (SR), la fibrilación auricular (AFIB) y la taquicardia sinusal (ST), que juntos suman cerca del 85 % de la base.



[Figura 1: Grafico de barras de las diferentes arritmias registradas]

Se procedió a realizar un análisis de los datos respecto al género encontrando que en la mayoría de las arritmias como lo son la SB, AFIB, ST, SF y SA representan mayor prevalencia en el género masculino mientras que cardiopatías como la SR y SVT, hay una mayor prevalencia en el género femenino.

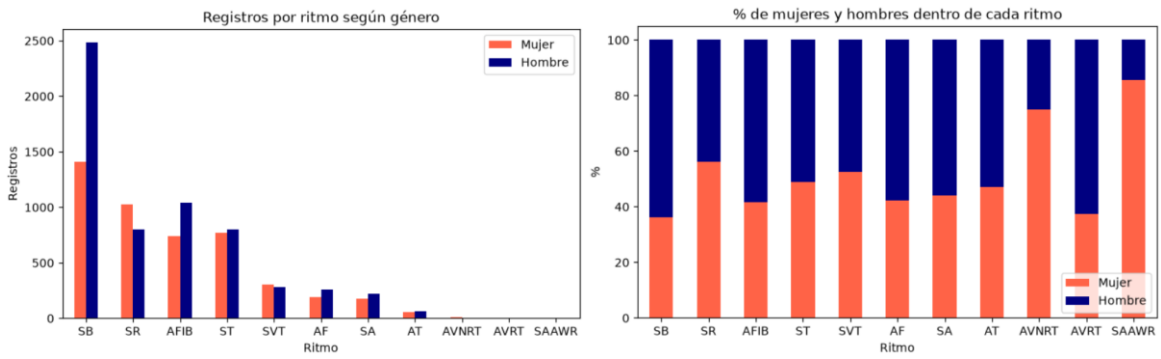
Por ejemplo, la fibrilación auricular presenta una mayor cantidad de registros correspondientes a hombres, con aproximadamente el 58 % de los registros, frente al 42 % de mujeres. Este comportamiento presenta una relación con estudios epidemiológicos que han encontrado una mayor prevalencia de fibrilación auricular en hombres en diferentes grupos de edad. Por ejemplo, el estudio ATRIA encontró una prevalencia general de 1,1 % en hombres y 0,8 % en mujeres, con un incremento importante en ambos sexos a medida que aumenta la edad.[1]

La taquicardia sinusal presenta una distribución relativamente equilibrada entre mujeres y hombres, con una ligera mayor representación masculina. Este resultado indica que, dentro de

la base de datos, no existe una diferencia tan marcada entre ambos grupos como la observada en SB o AFIB. Sin embargo, esta distribución no permite establecer que la taquicardia sinusal tenga una frecuencia equivalente en ambos sexos en la población general.

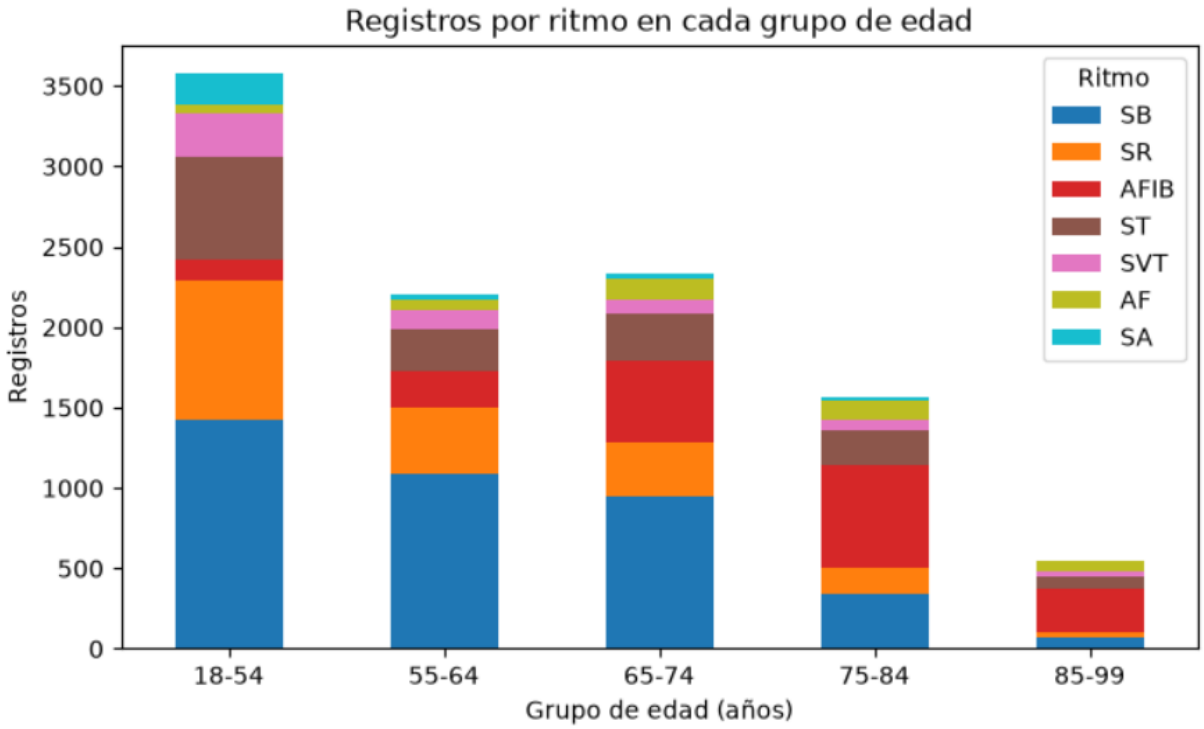
En las categorías AVNRT, AVRT y SAAWR se observan diferencias porcentuales importantes entre mujeres y hombres. Sin embargo, estas diferencias deben interpretarse con precaución, debido a que estas arritmias presentan una cantidad muy baja de registros. Cuando una clase tiene pocos ejemplos, incluso una diferencia de uno o dos registros puede modificar considerablemente el porcentaje.

Por esta razón, no se puede utilizar estas diferencias como evidencia de una asociación entre género y arritmia sin realizar previamente un análisis estadístico y considerar la cantidad de registros disponibles.



[Figura 2: Grafico de barras de las diferentes arritmias registradas por género y sus porcentajes]

En cuanto a la edad se realizaron las siguientes distribuciones basándonos en estudios de referencia [ver figura. 3]. Se observo que la distribución de los registros por grupo de edad muestra que la mayor cantidad esta entre la clase de 18 a 54 años, seguida por el grupo de 55 a 64 años. El ritmo SB presenta una representación importante en varios grupos de edad, mientras que AFIB destaca especialmente en los grupos de mayor edad, en particular en pacientes de 85 años o más. Por otra parte, este grupo presentan también la menor cantidad de registros.



[Figura 3: Grafico de las diferentes arritmias registradas por rango de edad]

Los algoritmos de aprendizaje automático requieren una cantidad suficiente de datos representativos para identificar patrones y realizar predicciones confiables. Sin embargo, la selección de los registros no debe depender únicamente de la cantidad total de datos disponibles, sino también de la distribución de las clases, las características demográficas de los pacientes y la variabilidad de las señales ECG.

Rhythm	Registros	Porcentaje (%)	Porcentaje acumulado (%)
SB	3889	36.53	36.53
SR	1826	17.15	53.68
AFIB	1780	16.72	70.40
ST	1568	14.73	85.13
SVT	587	5.51	90.64
AF	445	4.18	94.82
SA	399	3.75	98.57
AT	121	1.14	99.71
AVNRT	16	0.15	99.86
AVRT	8	0.08	99.93
SAAWR	7	0.07	100.00

[Figura 4: Tabla de porcentajes de las diferentes arritmias registradas por rango de edad]

A partir del análisis de la base de datos, se identificó una distribución desigual de los registros según el tipo de ritmo cardíaco [ver figura 3]. La bradicardia sinusal (SB) representa aproximadamente el 36,5 % de los registros, seguida del ritmo sinusal (SR), con el 17,2 %; la fibrilación auricular (AFIB), con el 16,7 %; y la taquicardia sinusal (ST), con el 14,7 %. En conjunto, estas cuatro clases concentran aproximadamente el 85,1 % de los registros disponibles [ver figura 4].

Por esta razón, se propone utilizar inicialmente estas cuatro categorías para desarrollar un modelo de clasificación multiclase. Esta selección permite aprovechar una cantidad considerable de registros y facilita el análisis del desempeño del algoritmo frente a diferentes tipos de ritmo cardíaco.

Respecto a la edad, se propone utilizar inicialmente todos los grupos etarios disponibles, comprendidos entre los 18 y 99 años.

El análisis de los porcentajes por grupo de edad evidencia que la composición de las arritmias cambia según la edad de los pacientes. En particular, la fibrilación auricular presenta una mayor representación en los grupos de edad avanzada, mientras que la bradicardia sinusal tiene una representación importante en los grupos de edad intermedios.

En cuanto a los resultados obtenidos presentan una relación con los estudios científicos consultados, tanto en las características de las arritmias como en la utilización de algoritmos de aprendizaje automático para su clasificación y predicción.

En primer lugar, Gadaleta et al. (2023) [2] desarrollaron un modelo de aprendizaje profundo para predecir la aparición de fibrilación auricular a partir de registros ECG que no presentaban esta arritmia durante el periodo analizado. El estudio consideró diferentes grupos de edad, incluyendo 18–54, 55–64, 65–74, 75–84 y 85–99 años, con el propósito de evaluar el desempeño del modelo en diferentes poblaciones etarias. Esta metodología presenta una relación directa con la distribución de edades utilizada en el presente análisis y respalda la importancia de evaluar los algoritmos considerando las características demográficas de los pacientes.

Por otra parte, Zheng et al. (2020) [3] desarrollaron un sistema de clasificación automática de arritmias utilizando señales ECG de 12 derivaciones. El estudio consideró cuatro categorías principales: fibrilación auricular, taquicardia supraventricular, bradicardia y ritmo sinusales. Estas categorías presentan una coincidencia con algunas de las clases disponibles en la base de datos analizada, especialmente SB, SR y AFIB.

Finalmente, Liu et al. (2024) [4] desarrollaron un modelo basado en redes neuronales convolucionales para clasificar diferentes arritmias a partir de señales ECG de una sola derivación. El estudio consideró nueve categorías de ritmo cardíaco y evaluó segmentos de señal de 5 y 10 segundos, obteniendo resultados que respaldan la utilización de técnicas de aprendizaje profundo para la clasificación automática de arritmias.

En conjunto, los artículos consultados respaldan la utilización de señales ECG para desarrollar algoritmos de clasificación y predicción de alteraciones del ritmo cardíaco. Asimismo, la distribución de edades observada en la base de datos presenta una relación con las tendencias descritas en la literatura.

Como alternativa se recomienda comparar el desempeño de los algoritmos utilizando las cuatro clases mayoritarias y evaluar el efecto en los grupos etarios de 18 a 74 años. ya que incluye los grupos con mayor cantidad de registros y permite conservar una población relativamente amplia, lo que permite disponer de una cantidad suficiente de ejemplos para entrenar y evaluar los algoritmos.

Pues esta permite incluir adultos jóvenes, adultos de mediana edad y adultos mayores, población importante por lo anteriormente mencionado. Por lo tanto, seleccionar de 18 a 74 años permite conservar una población adulta relativamente amplia, sin concentrar el análisis exclusivamente en un grupo de edad, pues, aunque esta caracterización reduzca parcialmente la variabilidad se sigue incluyendo una población heterogénea.

Punto 3: definición y utilidad del Biespectro

El biespectro es una herramienta en el análisis de señales que permite analizar las relaciones entre los componentes de frecuencia de una señal. Especialmente nos permite analizar las relaciones entre la fase de diferentes componentes de frecuencia y si esas relaciones vienen de interacciones no lineales [5].

El espectro de potencia muestra en una señal cómo se distribuye la potencia en sus frecuencias y a diferencia de esto el biespectro permite conocer si hay relaciones entre los componentes de frecuencia de la señal con información de la fase y posibles interacciones no lineales. Permite revelar información adicional de las características de una señal que el espectro de potencia no puede por sí solo [5].

Punto 4: Análisis descriptivo de las características espectrales fMP y sFSB

Se realizó un análisis descriptivo de las características espectrales fMP y sFSB para las arritmias AFIB, AT, SB y SR, considerando tanto la población completa como el subgrupo de pacientes con edades comprendidas entre los 18 y 74 años. El objetivo fue evaluar el comportamiento de estas características espectrales y observar posibles variaciones asociadas a la restricción del rango de edad.

Para la característica fMP, se observó un patrón descriptivo consistente en ambas poblaciones. La arritmia AT presentó los valores centrales más elevados, mientras que SB mostró los valores más bajos. Asimismo, las medias y medianas de las cuatro arritmias fueron relativamente similares entre la población completa y el subgrupo de 18 a 74 años. Se identificó una disminución de las desviaciones estándar al restringir el análisis por edad,

especialmente en AFIB y AT, lo que podría indicar una menor dispersión de los valores de fMP dentro del rango etario seleccionado.

En cuanto a sFSB, SB presentó los valores centrales más elevados en ambas poblaciones, mientras que AT mostró los valores centrales más bajos. A diferencia de fMP, las variaciones de las medias y medianas de sFSB entre las poblaciones no siguieron una tendencia uniforme. Además, se observaron desviaciones estándar elevadas en todos los grupos, lo que evidencia una considerable variabilidad de esta característica espectral. La diferencia entre las medias y medianas también sugiere posibles distribuciones asimétricas hacia valores altos.

En conjunto, los resultados muestran que las características espectrales presentan comportamientos descriptivos particulares según el tipo de arritmia. Aunque la restricción de edad no modificó sustancialmente los patrones generales de fMP y sFSB, se observaron variaciones en la dispersión y en algunos valores centrales.

=== INFORME DE ESTADÍSTICA DESCRIPTIVA (SUBGRUPO 1: POBLACION COMPLETA) ===

Tipo_Patologia		AFIB	AT	SB	SR
fMP	count	1780.00	121.00	3889.00	1826.00
	mean	4.28	5.17	2.69	3.71
	std	3.28	3.38	2.39	1.89
	min	0.10	0.80	0.40	0.70
	25%	2.30	3.30	1.00	2.50
	50%	3.40	4.50	2.70	3.60
	75%	4.90	5.60	3.70	4.50
	max	50.00	23.40	50.00	15.50
sFSB	count	1780.00	121.00	3889.00	1826.00
	mean	3574.45	3168.10	4855.87	3644.39
	std	3388.05	3387.87	3726.71	3274.72
	min	76.00	115.00	182.00	366.00
	25%	1585.00	1290.00	2312.00	1717.00
	50%	2513.00	1961.00	3640.00	2607.50
	75%	3806.25	3287.00	5483.00	3841.50
	max	15610.00	15487.00	15846.00	15597.00

=== INFORME DE ESTADÍSTICA DESCRIPTIVA (SUBGRUPO 2: 18 a 74 años) ===

Tipo_Patologia		AFIB	AT	SB	SR
fMP	count	871.00	77.00	3457.00	1611.00
	mean	4.30	5.08	2.62	3.69
	std	2.83	2.80	2.15	1.87
	min	0.20	1.00	0.40	0.70
	25%	2.60	3.50	1.00	2.50
	50%	3.60	4.60	2.60	3.60
	75%	5.00	5.50	3.70	4.50
	max	23.10	15.40	50.00	15.50
sFSB	count	871.00	77.00	3457.00	1611.00
	mean	3511.07	3288.22	4911.63	3674.70
	std	3343.03	3323.05	3754.41	3292.29
	min	328.00	115.00	182.00	490.00
	25%	1626.00	1459.00	2341.00	1729.00
	50%	2468.00	2181.00	3688.00	2628.00
	75%	3718.50	3816.00	5556.00	3854.50
	max	15567.00	15487.00	15846.00	15597.00

[Figura 5: Tabla de informes estadísticos descriptivos]

Punto 5: diferencias estadísticas entre las características espectrales para las poblaciones de estudio.

Con el propósito de determinar si existen diferencias estadísticamente significativas entre las características espectrales de las señales ECG correspondientes a las diferentes poblaciones de estudio, se analizaron la frecuencia de máxima potencia (fMP) y la suma de frecuencias significativas de bicoherencia (sFSB).

La frecuencia de máxima potencia representa la frecuencia que presenta el mayor valor de potencia en el espectro de la señal, mientras que la sFSB permite cuantificar las frecuencias que superan el umbral de significancia establecido para el análisis de bicoherencia.

Para evaluar las diferencias entre los tipos de ritmo cardíaco, se utilizó la prueba no paramétrica de Kruskal-Wallis, considerando un nivel de significancia de 0,05. Esta prueba permite comparar las distribuciones de las características espectrales entre varios grupos independientes sin requerir que los datos presenten una distribución normal.

Para la población comprendida entre los 18 y 74 años, al igual que para la población completa se evaluaron los supuestos de normalidad y homogeneidad de varianzas de las características espectrales fMP y sFSB. La prueba de Shapiro-Wilk evidenció desviaciones estadísticamente significativas de la normalidad para las cuatro arritmias. Asimismo, la prueba de Levene mostró diferencias significativas entre las varianzas de los grupos para fMP y sFSB. Debido a estos resultados, se consideró apropiado utilizar la prueba no paramétrica de Kruskal-Wallis para evaluar las diferencias entre las arritmias en esta población.

Entonces para la población completa, se aplicó la prueba no paramétrica de Kruskal-Wallis con el propósito de evaluar diferencias en las características espectrales fMP y sFSB entre las arritmias AFIB, SB, SR y ST. Los resultados evidenciaron diferencias estadísticamente significativas para fMP ($H = 1800.61166$; $p < 0.001$) y sFSB ($H = 951.92216$; $p < 0.001$) [ver figura 6]. En consecuencia, se rechazó la hipótesis nula de igualdad de distribuciones entre los grupos para ambas características. Estos resultados indican que al menos una de las arritmias presenta diferencias en sus características espectrales.

	Característica	Prueba	Estadístico H	p-valor	Resultado
0	fMP	Kruskal-Wallis	1800.61166	0.0	Diferencias significativas
1	sFSB	Kruskal-Wallis	951.92216	0.0	Diferencias significativas

[Figura 6: prueba de Kruskal-Wallis para población completa]

Por otro lado, para la población comprendida entre 18 y 74 se encontraron diferencias estadísticamente significativas para fMP ($H = 1635.48534$; $p < 0.001$) y sFSB ($H = 831.02578$; $p < 0.001$) [ver figura 7]. Por consiguiente, también se rechazó la hipótesis nula de igualdad de distribuciones entre las arritmias para ambas características. Estos resultados indican que, incluso al restringir el análisis a pacientes de 18 a 74 años, se mantienen diferencias estadísticamente significativas en las características espectrales de los ritmos estudiados.

	Característica	Prueba	Estadístico H	p-valor	Resultado
0	fMP	Kruskal-Wallis	1635.48534	0.0	Diferencias significativas
1	sFSB	Kruskal-Wallis	831.02578	0.0	Diferencias significativas

[Figura 7: prueba de Kruskal-Wallis para población de 18 a 74]

Los hallazgos descriptivos complementan los resultados inferenciales obtenidos mediante Kruskal-Wallis, los cuales evidenciaron diferencias estadísticamente significativas entre las arritmias en ambas poblaciones.

No obstante, las diferencias descriptivas entre la población completa y el subgrupo de 18 a 74 años no constituyen, por sí mismas, evidencia de diferencias estadísticas entre dichas

poblaciones. Asimismo, la significancia estadística entre las arritmias no garantiza que las características espectrales permitan clasificarlas correctamente.

Conclusiones:

- Analizando las tres metodologías de los artículos se puede concluir que el aprendizaje automático es una alternativa en el análisis de señales electrocardiográficas (ECG). Permiten predecir aspectos como el riesgo de fibrilación auricular e incluso clasificar distintos ritmos cardíacos. Hay diferencias en los estudios entre las técnicas utilizadas ya que el primero se enfoca en la predicción del riesgo desde las características de la señal del ECG, el segundo compara algoritmos en los que se usan combinaciones de características y el tercero usa redes neuronales convolucionales que le permiten reconocer ritmos desde registros de una derivación y diferente duración. Todas las técnicas muestran que el rendimiento de un modelo depende tanto del algoritmo como de la calidad y la preparación de los datos. Son metodologías que pueden apoyar el análisis de ECG de manera automática.
- Las métricas de desviación, compresión, bicoherencia y biespectro permiten analizar diferentes características de las señales de ECG de manera complementaria. La desviación cuantifica la variabilidad de la señal, la compresión da información sobre su redundancia y complejidad, por otro lado, el biespectro y la bicoherencia permiten estudiar las relaciones entre componentes de frecuencia y la estabilidad de sus fases. Estas métricas en conjunto dan una visión más amplia de las características de las señales, lo que ayuda a identificar diferencias relevantes entre los tipos de arritmias.
- A partir del análisis estadístico de las características espectrales fMP y sFSB, se identificaron diferencias estadísticamente significativas entre los tipos de arritmia AFIB, SB, SR y ST, tanto en la población completa como en el subgrupo de pacientes con edades entre 18 y 74 años. los hallazgos sugieren que las características espectrales estudiadas contienen información que permite identificar diferencias entre los tipos de ritmo cardíaco, incluso al restringir el análisis a un rango de edad específico. No obstante, la significancia estadística no implica necesariamente que estas características permitan clasificar correctamente cada arritmia. Para evaluar su utilidad como variables de entrada en algoritmos de aprendizaje automático, sería necesario complementar el análisis con métricas de desempeño de clasificación.

Bibliografía:

[1] Go, A. S., Hylek, E. M., Phillips, K. A., Chang, Y., Henault, L. E., Selby, J. V., & Singer, D. E. (2001). Prevalence of diagnosed atrial fibrillation in adults: National implications for rhythm management and stroke prevention: The AnTicoagulation and Risk Factors In Atrial Fibrillation (ATRIA) Study. *JAMA, 285*(18), 2370–2375. https://doi.org/10.1001/jama.285.18.2370

[2] Gadaleta, M., Harrington, P., Barnhill, E., Hytopoulos, E., Turakhia, M. P., Steinhubl, S. R., & Quer, G. (2023). Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias. npj Digital Medicine, 6, Article 229. https://doi.org/10.1038/s41746-023-00966-w

[3] Zheng, J., Chu, H., Struppa, D., Zhang, J., Yacoub, S., El-Askary, H., Chang, A., Ehwerhemuepha, L., Abudayyeh, I., Barrett, A., Fu, G., Yao, H., Li, D., Guo, H., & Rakovski, C. (2020). Optimal multi-stage arrhythmia classification approach. Scientific Reports, 10, Article 2898. https://doi.org/10.1038/s41598-020-59821-7

[4] Liu, L.-R., Huang, M.-Y., Huang, S.-T., Kung, L.-C., Lee, C.-H., Yao, W.-T., Tsai, M.-F., Hsu, C.-H., Chu, Y.-C., Hung, F.-H., & Chiu, H.-W. (2024). An arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection. Heliyon, 10(5), Article e27200. https://doi.org/10.1016/j.heliyon.2024.e27200

[5] D. Wong, D. A. Clifton, and L. Tarassenko, “An introduction to the bispectrum for EEG analysis,” in Proceedings of the 5th UK & Republic of Ireland Postgraduate Conference in Biomedical Engineering and Medical Physics (PGBIOMED09), Oxford, U.K., 2009, pp. 61–62. [Online]. Available: https://www.robots.ox.ac.uk/~davidc/pubs/pgbiomed_proc.pdf